

Modelli di Machine Learning per la Diagnosi del Diabete: Uno Studio Comparativo

Stefano Caprioli (s339841), Martina Cristiani (s348736), Fabio Daniele Diena (s332743),
Maddalena Ghiotti (s332834), Alberto Prino (s348174)

Abstract—Identificare precocemente i soggetti a rischio di diabete attraverso l'analisi di dati clinici e anagrafici è fondamentale per l'assistenza sanitaria preventiva. Nel corso dello studio, è stata eseguita un'analisi esplorativa del dataset clinico e sono state applicate tecniche di pre-processing per la gestione dei valori mancanti, l'eliminazione delle anomalie, il bilanciamento delle classi, la standardizzazione e la riduzione della dimensionalità. Sono stati quindi confrontati diversi modelli predittivi per l'identificazione del diabete: K-Nearest Neighbors, Support Vector Machine, Multi-Layer Perceptron, Random Forest e Histogram Gradient Boosting. Le performance, valutate tramite F1-score, hanno mostrato le migliori prestazioni per gli ultimi 2 modelli. I risultati ottenuti in fase di test confermano il potenziale delle tecniche di Machine Learning nell'ambito della diagnosi precoce del diabete. Sono tuttavia da tenere in considerazione le norme relative alla privacy e al trattamento di dati sensibili.

Index Terms—Machine Learning, Classificazione, Diabete, MLP, SVM, KNN, RandomForest, HistGradientBoosting.

I. INTRODUZIONE


Il diabete è una patologia cronica che interessa centinaia di milioni di persone in tutto il mondo ([ISS \[2022\]](#)). Nel contesto della gestione delle risorse sanitarie, vi è una crescente necessità di strumenti predittivi affidabili per identificare gli individui a rischio di sviluppare il diabete. Il dataset utilizzato contiene una serie di caratteristiche cliniche e demografiche associate ai principali fattori di rischio. Sono incluse variabili come sesso, età, ipertensione, malattie cardiache e storia di fumo, oltre a biomarcatori chiave: indice di massa corporea (BMI), livello di HbA1c (emoglobina glicata, che monitora i livelli di glucosio nel sangue degli ultimi 2-3 mesi) e livello di glucosio nel sangue. Ulteriori metriche cliniche derivate, come una stima della sensibilità insulinica, una variabile d'interazione tra BMI e glucosio, e i livelli di Troponina T (un marcatore altamente specifico per lesioni cardiache acute) ampliano il dataset. Analizzando i dati mediante cinque modelli di classificazione, ci siamo proposti di identificare pattern significativi che possano supportare una diagnosi precoce del diabete e minimizzare i rischi nella pratica clinica, considerando come variabile target la presenza della malattia, definita in modo binario: 0 per assenza e 1 per presenza.

Il codice e il dataset sono disponibili su [GitHub](#).

II. ANALISI E TRASFORMAZIONE DEI DATI

Il dataset di addestramento è costituito da 588 record, mentre quello di test ne include 148. Ogni record è rappresentativo di un individuo caratterizzato da 11 feature.

Fig. 1: Distribuzione delle età nel training set.



A. Analisi esplorativa del training set

Nel campione analizzato, l'età non è espressa come numero intero, ma include frazioni di anno (mesi, giorni, ecc.). È stata riscontrata la presenza di individui con età registrata negativa, e quindi non valida. Inoltre, la distribuzione delle età valide è compresa approssimativamente tra 0 e 80 anni, con un picco tra i 50 e i 70 anni, come illustrato in [Fig. 1](#). Un altro dato ritenuto errato riguarda un individuo con un valore di BMI pari a 94, notevolmente superiore alla norma e altamente improbabile. Tale valore corrisponderebbe a un peso superiore a 300 kg per un'altezza di 1,80 m.

Il dataset risulta sbilanciato, con circa il 75% dei record riferiti a soggetti non affetti da diabete. La distribuzione per genere è invece equilibrata. Le persone con ipertensione e/o patologie cardiache rappresentano una minoranza (8,5% e 3,5% rispettivamente), concentrata prevalentemente nella fascia d'età tra i 50 e i 70 anni, in proporzione alla distribuzione totale delle età. L'unico attributo con valori mancanti è la sensibilità all'insulina, variabile già elaborata, che presenta sia valori negativi sia positivi.


L'unico attributo categorico che presenta più di due valori distinti è "smoking history". Una delle categorie è costituita dagli individui per i quali non sono disponibili informazioni, e rappresenta una porzione consistente del training set, pari a circa un terzo, come riportato in [Tab. 1](#). Ulteriori criticità riguardano la presenza di etichette poco interpretabili, come "ever", o difficilmente distinguibili, come "former" e "not current". È inoltre possibile analizzare la relazione tra età e abitudine al fumo in [Fig. 2](#), dove si osservano due bambini di età inferiore ai 10 anni registrati come fumatori. Dalla stessa [Fig. 2](#) si nota che le etichette "never" e "no info" sono associate a individui di qualsiasi età, mentre le restanti sono prevalentemente riferite a persone di età superiore ai 19 anni.

È stata inoltre indagata la correlazione tra le variabili, riportando in [Fig. 3](#) quelle che presentano una correlazione superiore a 0,25 con la variabile target. Si osserva che le variabili maggiormente correlate con il diabete sono il livello

Tab. 1: Distribuzione di “smoking history” nel training set.

smoking history	numero record
never	206
no info	192
former	81
current	58
not current	32
ever	19

Fig. 2: Relazione tra età e “smoking history” nel training set.



di emoglobina glicata nel sangue (HbA1c) e l'interazione tra BMI e glucosio. Quest'ultima, com'è prevedibile, mostra una forte correlazione sia con il BMI che con il livello di glucosio.

Infine abbiamo valutato tramite il grafico in Fig. 4 la capacità di due soli attributi di discriminare tra le due classi del target, riscontrando una separabilità generale ma non completa.

B. Pre-processing


Il pre-processing è stato condotto eseguendo il fitting unicamente sul set di training, e successivamente applicando la trasformazione risultante sia al training set che al test set.

Si è iniziato eliminando le righe del dataset contenenti errori, ovvero età negative e valori di BMI eccessivamente elevati (superiori o uguali a 70). Successivamente, i valori mancanti relativi alla stima della sensibilità all'insulina sono stati imputati utilizzando la media degli altri record ed è stata codificata la variabile categorica “gender” (0-1). A causa delle incongruenze riscontrate nella variabile “smoking history”, quali la presenza di bambini fumatori, sono state considerate due opzioni. La prima consisteva nell'eliminazione di tale variabile inaffidabile. La seconda prevedeva l'assegnazione della classe “never” ai bambini di età inferiore o uguale ai 10 anni, seguita da un one-hot encoding con rimozione della colonna “no info”, implicitamente riconoscibile dalle colonne relative al fumo, nel caso in cui tutte risultino *false*. Successivamente è stata valutata anche l'eliminazione del campo “Interazione bmi-glucosio”, data l'alta correlazione con il BMI e con il livello di glucosio nel sangue.

Fig. 3: Correlazione tra alcuni attributi ed il target.

	gender	age	bmi	HbA1c level	blood glucose level	BMI Glucose Interaction	diabetes
gender	0.07	-0.00	0.20	0.07	0.05	0.26	
age		0.32	0.23	0.19	0.33	0.43	
bmi			0.20	0.22	0.66	0.46	
HbA1c level				0.33	0.36	0.59	
blood glucose level					0.83	0.47	
BMI Glucose Interaction						0.60	
diabetes							

Fig. 4: Relazione BMI–Glucosio–Diabete nel training set.



Inoltre, a fronte dello sbilanciamento della variabile target, si è preso in considerazione l'uso dell'oversampling sulla classe minoritaria rappresentata dalle persone diabetiche. Al fine di migliorare le performance, sono state esplorate tecniche di feature augmentation (combinazioni di variabili): in particolare, somme e sottrazioni tra variabili binarie, seguite da una normalizzazione Min-Max, e moltiplicazioni e divisioni tra variabili continue. Indipendentemente da strategia e modello adottati, tutte le feature non binarie sono state standardizzate. Infine, è stata valutata un'analisi delle componenti principali (PCA), selezionando una varianza spiegata pari al 97,5% sulla base del knee plot, al fine di ridurre il numero di feature.

III. METODOLOGIA

Per effettuare la previsione sono stati adottati e testati cinque diversi modelli di classificazione. Per garantire la riproducibilità dei risultati, il seed utilizzato in tutti i passaggi è stato fissato a 42.

A. Selezione dei modelli

I modelli scelti sono descritti di seguito insieme a una breve spiegazione del loro funzionamento e alle principali motivazioni della loro scelta.

- **K-Nearest Neighbour (KNN):** Il KNN è un classificatore *instance-based* che, senza una vera fase di addestramento, assegna una classe a una nuova istanza confrontandola con l'intero training set. Calcola la distanza tra il nuovo punto e tutti quelli di training, seleziona i K più vicini e assegna la classe più frequente tra essi. I vicini possono contribuire in modo uniforme (stesso peso) o *distance-based* (peso maggiore ai più vicini). La scelta del modello è motivata dal desiderio di includere anche un algoritmo *instance-based*, così da offrire un confronto più completo tra diverse tipologie di modelli.
- **Support Vector Machines (SVM):** La SVM è un classificatore *hyperplane-based* che cerca il miglior iperpiano separatore nello spazio delle feature che bipartisca i dati con rispetto alla variabile target. L'algoritmo introduce un margine di errore nella previsione caratterizzato dal parametro C . Richiede inoltre standardizzazione poiché i dati possono avere dimensioni molto differenti tra loro. Può essere applicato anche al caso di dati non linearmente separabili tramite il metodo kernel [Mohri et al., 2018]. La selezione del modello è basata sulla parziale separabilità notata in subsection II-A e sulle buone performance dimostrate in contesti simili [Kumari et al., 2013].

- **Multi-layer Perceptron (MLP):** Una rete neurale è un modello di apprendimento ispirato al cervello umano, composto da nodi (neuroni artificiali) organizzati in strati, che apprende a riconoscere schemi nei dati attraverso l'addestramento. Gli MLP sono reti neurali completamente connesse, senza collegamenti che formano cicli. La scelta di tale modello è dettata dalla sua potenza predittiva dimostrata in molti ambiti contemporanei. Tuttavia, ci aspettiamo performance peggiori rispetto ad altri modelli testati, dal momento che solitamente risulta più adatto con dataset di dimensione elevata.
- **Random Forest (RF):** Il RF è un classificatore *tree-based* che combina diversi alberi decisionali, ciascuno addestrato su porzioni diverse (anche sovrapposte) del dataset. Le motivazioni della scelta del modello sono le alte performance mostrate in altri contesti e la velocità di addestramento, che consente l'esplorazione di uno spettro più ampio di pre-processing e iperparametri.
- **Histogram Gradient Boosting (Hist):** L'Hist è un classificatore *tree-based* costituito da un insieme di alberi decisionali ottimizzati in modo sequenziale per minimizzare la funzione di loss. Considerate le buone prestazioni del Random Forest (RF), si è deciso di testare l'Hist, un modello simile ma che, come dimostrato da [Hastie et al. \[2009\]](#), risulta superiore in performance. In genere, l'Hist raggiunge il massimo delle sue prestazioni con dataset di grandi dimensioni.

B. Tuning degli iperparametri

In base al funzionamento di ciascun modello, sono state selezionate le tecniche di pre-processing (II-B) più adeguate e validate in combinazione con diverse configurazioni di iperparametri. I dettagli degli iperparametri considerati (Tab. 2), sono consultabili nella documentazione di [scikit-learn](#).

Tutti gli attributi valutati ed estratti nel pre-processing sono stati presi in considerazione. Per ogni modello è stata quindi eseguita una grid-search con cross-validation, che ha permesso di identificare configurazioni efficaci per gli iperparametri scelti. La cross-validation è stata condotta con 10 fold, una scelta motivata dalle dimensioni contenute del dataset. La metrica utilizzata per la valutazione delle prestazioni sulle porzioni di validazione è stata la F1-score.

$$F_1 = 2 \cdot \frac{\text{precisione} \cdot \text{recall}}{\text{precisione} + \text{recall}} \in [0, 1].$$

Indicando con TP , FP , TN e FN rispettivamente i veri positivi, falsi positivi, veri negativi e falsi negativi, la precisione e il recall, di dominio $[0, 1]$, sono calcolati come:

$$\text{precisione} = \frac{TP}{TP + FP}, \quad \text{recall} = \frac{TP}{TP + FN}.$$

Come si deduce dalla formula, il recall premia i modelli che tendono a classificare più campioni come positivi, mentre la precisione favorisce un comportamento più conservativo nella classificazione positiva.

Nel contesto medico, è spesso più importante identificare correttamente tutti i pazienti affetti dalla malattia, anche a costo di sottoporre a ulteriori analisi individui sani. Questo giustifica una preferenza per il recall; tuttavia, tale metrica

va interpretata con cautela: ad esempio, classificare tutti i campioni come positivi porterebbe a un recall pari a 1, ma renderebbe l'analisi priva di significato. Anche l'accuratezza:

$$\text{accuratezza} = \frac{TP + TN}{TP + TN + FP + FN} \in [0, 1],$$

è stata esclusa come metrica per la selezione del modello, dal momento che anch'essa può portare a risultati privi di significato con un dataset sbilanciato. Per ovviare a questi problemi, è stato deciso di utilizzare l'F1-score, in quanto bilancia le tendenze di precisione e recall.

Al fine di esplorare con maggiore precisione le aree più promettenti dello spazio degli iperparametri, nel costruire la grid-search, abbiamo tarato la griglia degli iperparametri dimodoché i valori con prestazioni migliori non si trovassero ai margini di essa. Pertanto, per ciascun modello sono state effettuate multiple grid-search di raffinamento.

IV. RISULTATI SPERIMENTALI

La natura relativamente semplice del compito ha permesso di ottenere buone performance con tutti i modelli sperimentati. In Tab. 2 sono riportati gli iperparametri e l'F1-score del modello migliore in validation, per ciascun algoritmo. In Fig. 5 sono riportate le performance del medesimo sul test set.

Il KNN presenta come principale criticità il calcolo delle distanze, operazione costosa su dataset di grandi dimensioni. Nel caso specifico, però, grazie alle dimensioni ridotte del dataset, i tempi richiesti sono risultati contenuti, permettendo di sperimentare agevolmente diverse combinazioni di pre-processing e configurazioni del modello. A priori si è scelto di aumentare le feature solo con PCA per evitare la *curse of dimensionality*. Nonostante le configurazioni con K bassi siano notoriamente più sensibili agli outlier, sono state incluse, in quanto risultate le più performanti secondo la grid-search.


Per la SVM, si nota innanzitutto che la forma lineare malperforma sul dataset a causa della non separabilità lineare dei dati. Si ottengono risultati notevolmente migliori con le kernel SVM. Vengono presi in considerazione i kernel: polinomiale, sigmoidale ed rbf. Una prima grid-search con un ridotto numero di valori per gli iperparametri gamma e C ha mostrato che il kernel rbf si conferma consistentemente il più performante su tutte le tipologie di pre-processing. Si è eseguita pertanto una grid-search di raffinamento solo con kernel rbf.

L'MLP si è mostrato generalmente più performante quando addestrato su dati preprocessati con oversampling, registrando valori di F1 più alti sia in validation che in test e confermando la sua efficacia su dataset più ampi (nel caso senza oversampling, l'F1-score medio migliore in validation è pari a 0.913). I modelli migliori hanno privilegiato architetture profonde e ampie, con funzione di attivazione *ReLU*, risultata più efficace rispetto a *tanh*. La miglior combinazione di iperparametri, individuata nella prima fase di raffinamento della grid-search, ha prodotto ottimi risultati in validation, ma il modello pre-raffinamento ha ottenuto F1 superiori su training e test. Valore ancora più alto sul test set, pari a 0.973, è stato raggiunto nel caso in cui si è applicato oversampling e rimozione della feature correlata.

Tab. 2: Pre-processing, iperparametri selezionati ed F1-score del modello migliore in validation.

Modello	Pre-processing	Iperparametri	F1
KNN	Oversampling	K: 2, metric: Manhattan, weights: uniform	0.982
SVM	Oversampling + PCA	kernel: rbf, C: 1, gamma: 1	0.986
MLP	Oversampling	activation: relu, alpha: 0.0001, batch_size: 25, hidden_layer_sizes: [75, 75, 75, 75, 75], max_iter: 1000	0.985
RF	Oversampling + Augmentation	max_depth: 10, n_estimators: 100, min_samples_leaf: 1, min_samples_split: 2	0.988
Hist	No feat. corr. + Oversampling	learning_rate: 0.2, max_depth: 5, max_iter: 100, max_leaf_nodes: 31, min_samples_leaf: 10	0.994

Fig. 5: Metriche sul test dei modelli migliori in validation.



Per quanto riguarda la Random Forest, i risultati evidenziano come il dataset originale e quello con la rimozione della “smoking history”, in combinazione con oversampling e feature augmentation, abbiano ottenuto le migliori performance complessive, con una F1-score di test pari a 0.973. PCA è la variante che ha ottenuto le performance peggiori ($F1 = 0.904$). La riduzione dimensionale tramite PCA può diminuire l’efficacia del modello RF, modificando distribuzione e relazioni delle feature originali. Complessivamente, la RF si è dimostrata molto solida e performante sul dataset, grazie a un adeguato pre-processing.

L’Hist ha mostrato performance generalmente elevate, ma a differenza dell’MLP, i raffinamenti della grid-search non hanno portato a miglioramenti significativi rispetto ai modelli pre-raffinamento, nemmeno in validation. Anche l’aggiunta dell’augmentation non ha apportato benefici rilevanti, così come l’applicazione della PCA. Curiosamente, tutti i modelli migliori (uno per ogni combinazione di pre-processing) hanno classificato correttamente tutti i campioni del training set, ma le vere performance si sono osservate sul test set. Qui, i modelli addestrati senza oversampling né augmentation hanno ottenuto i risultati migliori, con F1-score pari a 0.973, un solo *FP* e un solo *FN*. Il modello con miglior F1 in validation ha ottenuto sul test 1 *FN* e 2 *FP*.

Dato il dataset di dimensioni ridotte e sbilanciato, l’uso dell’oversampling ha migliorato significativamente le performance di tutti i modelli, specialmente dell’MLP. Quest’ultimo ha tuttavia mostrato un recall molto basso sul test set che lo rende inadatto a un contesto medico. Al contrario, i modelli *tree-based* hanno ottenuto i migliori recall, così come il KNN, che tuttavia soffre di una precisione inferiore. L’SVM ha ottenuto precisione e recall ben bilanciate, dimostrandosi però inferiore in performance complessive. Confrontando RF e Hist, emerge come quest’ultimo sia più sensibile ai dati in input, come dimostrato dalla discrepanza tra le performance in training e test, sintomo anche di potenziale overfitting. Sotto quest’ultimo aspetto, RF si è dimostrato più robusto rispetto

sia a MLP che a Hist.

V. CONCLUSIONI

Dall’analisi emerge che modelli troppo complessi, come MLP e Hist, tendono a sovradattarsi ai dati, risultando controproducenti per un compito relativamente semplice. Inoltre, i due campioni del test set erroneamente classificati dalla RF potrebbero rappresentare soggetti anomali o evidenziare un limite nella rappresentatività dei dati di addestramento.

Il dataset analizzato in questo studio è piuttosto limitato e non risulta adatto per applicazioni su larga scala, anche se la disponibilità di dataset di grandi dimensioni nel settore medico è generalmente scarsa. Tuttavia, dataset più ampi e di qualità superiore, combinati con i risultati ottenuti in questo studio, potrebbero costituire una buona base per ricerche future. Tali dataset consentirebbero anche, senza perdita di generalizzazione, di sperimentare tecniche aggiuntive, quali feature selection o modelli ensemble costruiti a partire dai modelli già testati, come suggerito da [Hasan et al. \[2020\]](#).

Per quanto riguarda i settori di applicazione dei modelli, le compagnie assicurative beneficiano della diagnosi precoce del diabete, poiché consente di proporre piani personalizzati e contenere le perdite economiche, mentre i fornitori di servizi sanitari possono offrire un’assistenza più efficace grazie al supporto di algoritmi di machine learning, utili per:

- individuare soggetti a rischio tramite screening;
- definire piani di prevenzione personalizzati per chi non ha ancora sviluppato la malattia;
- adattare le cure in base ai dati dei pazienti già malati.

Tuttavia, la maggior parte delle applicazioni di Machine Learning in ambito medico, soprattutto quelle orientate all’uso da parte di assicurazioni, potrebbero essere impedito o limitate dalle normative europee sulla privacy. È essenziale considerare che si trattano dati sensibili e non aggregati, potenzialmente utilizzabili per scopi non etici o discriminatori. Ad esempio, le polizze assicurative personalizzate possono avere conseguenze discriminatorie che minano il principio stesso di mutualità. L’uso di modelli come il KNN, che memorizzano i dati originali, è ancora più critico e aggrava i rischi per la privacy. Inoltre, nell’ambito della prevenzione medica, resta aperta la questione della responsabilità legale in caso di danni causati da diagnosi errate da parte del modello.

VI. CONTRIBUTI

Il gruppo ha collaborato alle analisi preliminari. Diena ha elaborato il pre-processing dei dati. Ghiotti ha sviluppato i modelli MLP e HistGradientBoosting, Prino l’SVM, Cristiani il KNN e Caprioli la Random Forest. Il lavoro è stato caratterizzato dal confronto continuo tra tutti e le decisioni sono sempre state condivise dal gruppo.

REFERENCES

- Md Kamrul Hasan, Md Ashraful Alam, Dola Das, Eklas Hossain, and Mahmudul Hasan. Diabetes prediction using ensembling of different machine learning classifiers. *IEEE Access*, 8:76516–76531, 2020.
- Trevor Hastie, Robert Tibshirani, and Jerome H. Friedman. *The elements of statistical learning: data mining, inference, and prediction*, volume 2. Springer, 2009.
- Istituto Superiore di Sanità ISS. Aspetti epidemiologici nel mondo. <https://www.epicentro.iss.it/diabete/epidemiologia-mondo>, 2022. Accesso: 1 luglio 2025.
- V. Anuja Kumari, R. Chitra, et al. Classification of diabetes disease using support vector machine. *International Journal of Engineering Research and Applications*, 3(2):1797–1801, 2013.
- Mehryar Mohri, Afshin Rostamizadeh, and Ameet Talwalkar. *Foundations of Machine Learning (Second edition)*. The MIT Press, 2018.